

گزارش پروژه پایش وضعیت راننده با

Vision Transformer

محمد رضا مهري

401463176

آماده سازی مجموعه داده

در این پروژه از مجموعه داده **Driver Drowsiness Dataset** استفاده شده است که شامل تصاویر رانندگان در حالت های مختلف هوشیاری و خواب آلودگی می باشد. این داده ها از طریق Kaggle دریافت شدند. پس از دانلود، فایل ها به Google Drive منتقل شده و در محیط اجرایی بارگذاری شدند. برای مدیریت داده ها از کلاس ImageFolder در کتابخانه PyTorch استفاده شد.

به منظور کاهش زمان آموزش و امکان انجام آزمایش های متعدد، تنها ۲۰ درصد از کل داده ها انتخاب گردید. سپس داده های انتخاب شده به سه بخش آموزش، اعتبارسنجی و آزمون تقسیم شدند. سهم داده ها به ترتیب ۷۰ درصد برای آموزش، ۱۵ درصد برای اعتبارسنجی و ۱۵ درصد برای آزمون در نظر گرفته شد. این تقسیم بندی به صورت تصادفی و با استفاده از مقدار seed ثابت انجام شد تا نتایج قابل تکرار باشند.

آمار داده ها

تعداد کل تصاویر اصلی: حدود ۲۰۰۰۰

تعداد تصاویر استفاده شده (۲۰٪): ۴۰۰۰

تعداد تصاویر آموزشی: ۲۸۰۰

تعداد تصاویر اعتبارسنجی: ۶۰۰

تعداد تصاویر آزمون: ۶۰۰

ساختار مدل Vision Transformer

ساختار مدل بر اساس ایده ارائه شده در مقاله

An Image is Worth 16x16 Words

طراحی گردید. در این پیاده سازی، مدل Vision Transformer به صورت کامل از ابتدا ساخته شد و از هیچ مدل از پیش آموزش دیده ای استفاده نشد.

مشخصات معماری

اندازه تصویر ورودی: 224x224

اندازه Patch: 32x32

تعداد Patch ها: 49

embedding: 64 بعد

تعداد Attention Head ها: 4

تعداد لایه های Transformer: 2

Feedforward: 128 بعد لایه

تعداد کلاس خروجی: 2

در این معماری، تصویر ابتدا به بخش های کوچک تر تقسیم شده و هر بخش به یک بردار ویژگی تبدیل می شود. سپس یک توکن ویژه CLS به ابتدای توالی افزوده می شود تا نماینده کل تصویر باشد. به منظور حفظ اطلاعات مکانی، embedding مکانی به توالی اضافه می شود. خروجی نهایی ترنسفورمر از طریق یک لایه LayerNorm و یک لایه Linear به دو کلاس هدف نگاشت می شود.

آموزش مدل و مقایسه بهینه سازها

تنظیمات آموزش

تعداد دوره ها (Epochs): ۲

اندازه بسته (Batch Size): ۶۴

تابع هزینه CrossEntropyLoss :

بهینه سازها Adam و SGD

نرخ یادگیری Adam: $3e-4$

نرخ یادگیری SGD: $1e-2$

مدل با استفاده از دو بهینه ساز Adam و SGD با مونتوم 0.9 آموزش داده شد.

تحلیل روند آموزش نشان داد Adam همگرایی سریع تری داشته و در تعداد دوره کم عملکرد بهتری ارائه می دهد. در مقابل، SGD روند پایدارتری داشت اما برای دستیابی به عملکرد مشابه به تعداد دوره بیشتری نیاز داشت. بر اساس نتایج اعتبارسنجی، مدل آموزش دیده با Adam به عنوان مدل نهایی انتخاب شد.

ارزیابی مدل

عملکرد مدل روی داده‌های آزمون ارزیابی شد و معیارهایی نظیر Accuracy و Precision محاسبه گردید.


adam

	precision	recall	f1-score	support	
Non-Drowsy		0.78	0.71	0.74	300
Drowsy		0.73	0.79	0.76	300
accuracy				0.75	600

نتایج مدل SGD:

	precision	recall	f1-score	support
Non-Drowsy	0.71	0.65	0.68	300
Drowsy	0.68	0.73	0.70	300
accuracy			0.69	600

تحلیل نتایج



مدل Adam با دقت کلی ۷۵٪ عملکرد بهتری نسبت به SGD با دقت

۶۹٪ داشته است. همچنین مدل در تشخیص کلاس خواب‌آلود عملکرد

بهتری دارد که از نظر ایمنی اهمیت بالایی دارد. حدود ۸۷ نمونه از رانندگان

هوشیار به اشتباه خواب‌آلود تشخیص داده شده‌اند که اگرچه باعث هشدار ا

ضافی می‌شود، اما نسبت به عدم تشخیص خواب‌آلودگی واقعی ایمن‌تر است.

تحلیل خطا

پس از ارزیابی مدل Adam، حدود ۱۵۰ تصویر از ۶۰۰ تصویر آزمون (۲۵٪) به اشتباه طبقه‌بندی شده بودند.

بررسی تصاویر خطا دار نشان داد مهم‌ترین عوامل ایجاد خطا عبارت‌اند از:

نور کم یا سایه شدید روی صورت

استفاده از عینک

قرمزی چشم‌ها


زاویه غیرمستقیم صورت نسبت به دوربین

نیمه‌باز بودن چشم‌ها

حالات چهره خنثی

نتایج نشان می‌دهد مدل در شرایط نوری نامناسب و تغییر زاویه دید عملکرد ضعیف‌تری دارد و وابستگی زیادی به ویژگی‌های ظاهری چشم دارد.


True: Non Drowsy
Pred: Drowsy




True: Non Drowsy
Pred: Drowsy



True: Non Drowsy
Pred: Drowsy



True: Non Drowsy
Pred: Drowsy



True: Non Drowsy
Pred: Drowsy



True: Non Drowsy
Pred: Drowsy



توسعه با توجه زمانی (Temporal Attention)

برای در نظر گرفتن وابستگی بین فریم‌های متوالی، سه تصویر پشت سر هم به عنوان ورودی در نظر گرفته شد. هر فریم توسط Vision Transformer ویرگی برداری شد و خروجی‌ها به یک Transformer زمانی داده شدند. تصمیم نهایی بر اساس خروجی گام زمانی آخر اتخاذ گردید.

دقت مدل پایه: ۷۵٪

دقت مدل زمانی: ۷۸.۵٪

افزایش ۳.۵ درصدی دقت نشان می‌دهد اطلاعات زمانی نقش مهمی در تشخیص دقیق‌تر خواب‌آلودگی دارد. مدل با در نظر گرفتن توالی فریم‌ها می‌تواند بین پلک زدن عادی و خواب‌آلودگی تمایز قائل شود.

بهینه‌سازی سرعت استنتاج

برای افزایش سرعت اجرا، از دقت نیمه‌اعشاری (FP16) استفاده شد.

زمان استنتاج با FP32: ۲.۳۴ ثانیه

زمان استنتاج با FP16: ۱.۵۶ ثانیه

بهبود سرعت: حدود ۳۳٪

دقت با FP32: ۷۵٪

دقت با FP16: ۷۴.۸٪

کاهش ۰.۲ درصدی دقت در مقابل افزایش ۳۳ درصدی سرعت نشان می‌دهد این روش برای کاربردهای real-time مناسب است.

یادگیری فدرال

در این بخش، داده‌های آموزشی میان سه کلاینت مستقل تقسیم شدند. هر کلاینت مدل را به صورت محلی آموزش داد و در نهایت وزن‌ها با روش Federated Averaging تجمیع شدند.

دقت مدل متمرکز: ۷۵٪

دقت مدل فدرال: ۷۳.۲٪

کاهش ۱.۸ درصدی دقت در یادگیری فدرال طبیعی است و به دلیل توزیع داده‌ها میان کلاینت‌ها رخ می‌دهد. مزیت اصلی این روش حفظ حریم خصوصی داده‌ها در سناریوهای واقعی است.

اگر بخواهی، می‌توانم دقیقاً بگویم چه فاصله خطوط (Line Spacing)، چه Margin و چه فونتی تنظیم کنی تا خروجی نهایی واقعاً شبیه گزارش پایان‌ترم حرفه‌ای شود.